

Medidas de la tendencia central

Media o promedio

Cálculo	Suma de todos los valores dividido por el número de valores.
Beneficios	Es el valor que produce la menor cantidad de error respecto a todos los demás valores del conjunto de datos.
Cuándo si usarla	Datos con distribución regular
Cuándo no usarla	Cuando hay valores atípicos o muy extremos. Susceptible a los valores atípicos o extremos Con datos sesgados (no representa la realidad)

Mediana

Cálculo	Es la puntuación media para un conjunto de datos ordenados en orden de magnitud. Es el número intermedio del rango de valores. Si el rango de valores es par, la mediana es el promedio de los 2 números centrales.
Beneficios	Menos afectada por valores atípicos o extremos
Cuándo si usarla	Con valores sesgados y ordinales
Cuándo no usarla	Cuando la media no es real

Modo

Cálculo	Es la puntuación más frecuente de un conjunto de datos.
Cuándo si usarla	Valores nominales
Cuándo no usarla	Cuando hay datos continuos y es probable que hayan varios populares (peso, transporte más usado...) No representa una tendencia central cuando la mayoría de los valores están en un extremo.

Dispersión

Las medidas más importantes de dispersión son la desviación estándar, la varianza, el rango y el rango intercuartil.

- **Desviación estándar y varianza:** Se basan en las desviaciones de los valores individuales de la media e indican hasta qué punto se dispersan los valores a su alrededor

	Desviación estándar	Varianza
Que es	Cuan ampliamente se distribuyen los valores alrededor de la media	Mide la dispersión alrededor de la media. Para una población, es la suma de las desviaciones al cuadrado respecto a la media poblacional dividida por N.
Cálculo	Raíz cuadrada de la varianza	Suma de las desviaciones al cuadrado divididas por el n.º de desviaciones -1 (media de las desviaciones)
Resultado	De cero a positivo. Cuanto mayor sea el resultado, mayor es la desviación.	
VS	La varianza se basa en desviaciones cuadráticas respecto a la media. La desviación estándar es el cuadrado raíz de varianza	

- **Rango:** También llamado envergadura. El mayor menos el menor.

Rango vs. desviación estándar: Ambos describen la dispersión de los datos, pero en formas diferentes. El rango solo usa los dos valores más extremos, lo que lo hace muy fácil de calcular pero también muy sensible a los valores atípicos. La desviación estándar toma cada valor en cuenta y resume las desviaciones al cuadrado respecto a la media

- **Cuartiles:** Divide los datos ordenados en cuatro partes
- **Rango intercuartil:** Describe la distribución del 50% central de los datos (del 25% al 75% o del primer cuartil al tercero).

Medidas de asimetría

Tipos de Asimetría

- **Simétrica** ($=0$): Los datos se reparten de forma equilibrada a ambos lados del centro; **la media, la mediana y la moda coinciden.**
- **Asimetría positiva o a la derecha** (>0): La cola de la distribución se alarga hacia los valores más altos (a la derecha). Generalmente se cumple que: **Moda < Mediana < Media.**
- **Asimetría negativa o a la izquierda** (<0): La cola de la distribución se alarga hacia los valores más bajos (a la izquierda). Generalmente se cumple que: **Media < Mediana < Moda.**

Tipo de asimetría	Descripción	Medida de tendencia central.
Simetría	Datos se reparten de forma equilibrada a ambos lados del centro	Media, mediana y moda coinciden
Asimetría positiva o derecha (>0)	La distribución se alarga hacia los valores más altos (derecha)	Moda < Mediana < Media
Asimetría negativa o izquierda (<0)	La distribución se alarga hacia los valores más bajos (izquierda)	Media < Mediana < Moda

Visualización estadística

Tipo de gráfico	Datos a representar	N.º categorías	Cuando si	Cuando no
Barras standard	Catégoricos o agrupados	1	Representar 1 categoría	Más de 1 categoría
Barras apiladas	Catégoricos o agrupados	+2	Representar varias categorías	comparar las piezas de subcomponentes en cada barra
Diagrama de sectores (quesitos)	Catégoricos o agrupados	+2	idea general de la relación parte-todo en tus datos o quien es más grande-pequeño	Evaluar los tamaños relativos de las categorías. Comparar datos entre tartas. Visualizar porcentajes que no suman el 100%
Treemap (cuadros con cuadros)	Catégoricos o agrupados	+2	Relación parte-todo de muchas categorías. Comparaciones precisas entre categorías no importantes Espacio escaso Datos jerárquicos	Dificulta entendimiento o abrumadores. Alternativas: barras apiladas
Histogramas: eje x: valores eje y: n.º valores	Variables continuas (edad, peso, temperatura...)	1 o +2	Evolución de los datos CONTINUOS. N.º valores por rangos. Útil para ver asimetrías.	
Boxplot.	Muestra el mínimo, máximo, mediana, cuartil interior y superior	1 o +2	Mucho contexto de varias categorías (nota de exámenes por asignaturas)	Representar distribución de datos (poca precisión). Puede ser complejo
Violinplot (como boxplot pero con forma alargada. Híbrido de boxplot y gráfico de densidad)			Mostrar picos de los datos de un boxplot. Mostrar estadísticas resumen y densidad para cada variable.	

Correlación y regresión lineal

La correlación lineal y la regresión lineal simple son métodos estadísticos que estudian la relación lineal existente entre dos variables

Por norma general, la correlación lineal va primero. Si se analizan las variables, y si están relacionadas, se procede a la generación de modelos de regresión lineal.

Correlación lineal

Cuantifica cómo de relacionadas están dos variables numéricas. Es necesario disponer de parámetros para cuantificar la relación. Uno de ellos es la covarianza.

Para hacer comparaciones se estandariza la covarianza como *coeficientes de correlación*. Destacan los coeficientes de:

- **Pearson:** funciona con variables cuantitativas con distribución normal. Sensible a extremos. Debe ser relación lineal.
- **Rho de Spearman:** con datos ordinales, de intervalo o no satisface la condición de normalidad y los datos se pueden transformar en rangos.
- **Tau de Kendall:** alternativa no paramétrica (no distribución normal) con rangos. Pocos datos y ocupan la misma posición en el rango.

Estos coeficientes de correlación van del +1/-1, siendo +1 la correlación positiva y el -1 negativa. (0: asociación nula; 0.1: asociación pequeña.; 0.3: asociación mediana.; 0.5: asociación moderada. ; 0.7: asociación alta.; 0.9: asociación muy alta.)

Aún teniendo un resultado cercado al +1/-1 hay que hacer el **t-test**

Scatterplot (diagrama de dispersión)

Cuantifica cómo de relacionadas están dos variables numéricas representadas simultáneamente en un eje horizontal y vertical.

Aspectos a tener en cuenta:

- Eliminar la línea de tendencia: si no es obvia podría generar confusión y si es obvia no hace falta mostrarla.
- Puntos transparentes al solaparse
- No es necesaria una base cero (0)
- Crear secciones y etiquetas da mayor claridad

Regresión lineal

Genera una ecuación (modelo) basándose en la relación existente entre ambas variables que permite predecir el valor de una a partir de la otra.

Estimador de mínimos cuadrados ordinarios (MCO)

Es el método más común.

Funcionan minimizando la suma de las diferencias al cuadrado entre los valores observados (reales) y los predichos a partir de la recta de regresión. A la diferencia se le llama residuos.

Cómo se utiliza

Ayuda a hacer predicciones y a comprender las relaciones entre la variable independiente y la dependiente. Por ejemplo, podrías querer saber cómo afecta la altura de un árbol (variable independiente) al número de hojas que tiene (variable dependiente). Recopilando datos y ajustando un sencillo modelo de regresión lineal, podrías predecir el número de hojas en función de la altura del árbol.

Ecuación

$$y = mx + b$$

m : pendiente de la recta

b : intercepto

Para la ciencia de datos es más probable:

$$y = b_0 + b_1 * x_1$$

b_0 : intercepto

b_1 : pendiente de la recta

Estadística inferencial

Diferencia entre estadística inferencial y descriptiva

La descriptiva resume y describe los datos de una muestra (media, mediana, moda, desviación estándar). La inferencial usa esos datos para hacer predicciones y generalizaciones sobre una población más amplia mediante pruebas de hipótesis, intervalos de confianza y análisis de regresión.

Test de hipótesis estadístico

Un test de hipótesis estadístico es un método utilizado para hacer inferencias sobre una población a partir de datos de muestra. Determinar si un resultado observado es probablemente debido a la casualidad o si representa un efecto real en la población.

Realizar un test de hipótesis típicamente implica los siguientes pasos:

- Formular la hipótesis nula y alternativa: la nula dice que no hay relación y la alternativa si.
- Recogida de datos y preparación
- Elegir un estadístico para evaluar las hipótesis: pruebas de estadística.
- Calcular el estadístico y el valor p
- Toma de decisiones: comparar valor p con nivel de significancia (α). $p < \alpha$ rechaza la hipótesis nula, $p > \alpha$ no la rechaza.

P-valor

El valor p indica la probabilidad de que se produzca el resultado observado o un resultado aún más extremo si la hipótesis nula es cierta. Normalmente se compara con un nivel de significación del 5%.

Intervalo de confianza (margen de error)

A partir de la muestra de datos, creas un intervalo de confianza para un test estadístico. De este modo, al dar un intervalo y no un número exacto da mayor confianza de acertar. Cuanto mayor sea el intervalo, mayor será la confianza. Normalmente el intervalo es la desviación estándar y el % de confianza es del 95%. Sin embargo, si se propone un intervalo de confianza muy extenso, no dice nada. Cuanto mayor es la muestra más acotado será el intervalo de confianza. La desviación (variabilidad) de los datos afecta también al nivel de confianza (cuanto mayor desviación peor nivel de confianza).

Para el cálculo del intervalo de confianza se necesita el n.º de observaciones (n), la media (x), desviación estándar (s) y el nivel de confianza (z):

Intervalo de confianza (%)	Z
80	1,282
85	1,440
90	1,645

95	1,960
99	2,576
99,5	2,807

La fórmula sería: $X \pm z \frac{s}{\sqrt{n}}$

El resultado sería el intervalo de confianza.

Tipos de pruebas de hipótesis

Prueba Z: Para muestras grandes ($n \geq 30$) con varianza poblacional conocida

Prueba T: muestras pequeñas ($n < 30$) con varianza desconocida. Compara medias.

Prueba F: comparar varianzas de dos poblaciones.

Intervalo de confianza: estima parámetros de una población con un nivel de certeza determinado

Chi cuadrada: Para buscar relación entre dos variables categóricas (sexo, nivel educativo, frecuencia que se ve la TV...)

T-test: Evalúa si una diferencia observada entre dos grupos es mayor de lo que normalmente se espera con la variación muestra. 3 versiones: prueba t de una sola muestra, independiente de dos muestras o muestras emparejadas.

ANOVA: Comprueba si existen diferencias estadísticamente significativas entre las medias de dos o más grupos.

Test de correlación: Pearson, Rho de Spearman, Tau de Kendall y otros.

Machine learning

Aprendizaje de Machine Learning se engloba, entre otros, en:

- Aprendizaje supervisado: predecir o explicar con unas variables X que explican una variable Y. Ej: estilo de vida (x) explica la esperanza de vida (y). Dependiendo del resultado esperado:
 - Regresión (numérica): esperanza de vida, sueldo esperado, riesgo... Intenta predecir a través de un algoritmo.
 - Clasificación (categoría): asignación de hipotecas... La y es la categoría y el algoritmo es encontrar una frontera para escoger la categoría.
- Aprendizaje no supervisado: Solamente tiene variable X, no variable respuesta (y). No hay criterio de bien o mal.
 - Agrupación: crear grupos a partir de los datos.
 - Detección de anomalías.
 - Reducción dimensional: pasar de muchas columnas a pocas perdiendo un % escaso de la información.

